

UNIVERSIDAD AUTÓNOMA DE ZACATECAS

UNIDAD ACADÉMICA DE MATEMÁTICAS

LICENCIATURA EN ACTUARÍA

Grandes Bases de datos



Actividad 1: Análisis de Componentes Principales

Presenta:

Brianna Camila Meza Dueñez

Profesor:

Dr. José Raúl Castro Esparza

Zacatecas, Zacatecas, a 31 de Agosto de 2026



Objetivo:

El principal objetivo de esta actividad es poder aplicar un análisis de componentes principales sobre la base de datos Iris, esto con el fin de poder reducir la dimensión de las variables numéricas y comprender la estructura de correlación que hay entre ellas. Hacemos 3 pasos, (1) extracción de datos y carga de ellos, (2) cálculo del PCA y de la varianza explicada, y (3) la construcción e interpretación de los mapas de observaciones y de factores.

Paso 1: Extracción de la base de datos

Nuestra base de datos Iris fue extraída desde una liga de GitHub y cargada en un DataFrame de Python usamos `pandas.read_csv`. Nuestra base contiene 150 observaciones que son flores y hay 5 columnas: largo y ancho del sépalo y pétalo; y una variable categórica que es `variety` que indica la especie que pueden ser: setosa, versicolor y virginica.

```
[2]: #Paso 1: Extraer datos iris
url = "https://gist.githubusercontent.com/netj/8836201/raw/iris.csv"
df = pd.read_csv(url)
df
```

```
[2]:
```

	sepal.length	sepal.width	petal.length	petal.width	variety
0	5.1	3.5	1.4	0.2	Setosa
1	4.9	3.0	1.4	0.2	Setosa
2	4.7	3.2	1.3	0.2	Setosa
3	4.6	3.1	1.5	0.2	Setosa
4	5.0	3.6	1.4	0.2	Setosa
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	Virginica
146	6.3	2.5	5.0	1.9	Virginica
147	6.5	3.0	5.2	2.0	Virginica
148	6.2	3.4	5.4	2.3	Virginica
149	5.9	3.0	5.1	1.8	Virginica

150 rows × 5 columns

Paso 2: Análisis de Componentes Principales

Estandarizamos las variables para que ninguna dominará solo por su escala. Con los datos estandarizados calculamos la matriz de correlaciones y a partir de ella los eigenvalores. También entrenamos el modelo de PCA sobre los datos estandarizados para poder obtener los mismos resultados de una forma automatizada.

```
[6]: #Matriz de correlaciones
A = (1/renglones) * np.dot(X2.T, X2)
A

[6]: array([[ 1.          , -0.11756978,  0.87175378,  0.81794113],
        [-0.11756978,  1.          , -0.4284401 , -0.36612593],
        [ 0.87175378, -0.4284401 ,  1.          ,  0.96286543],
        [ 0.81794113, -0.36612593,  0.96286543,  1.          ]])

[7]: #Entrenar al PCA
pca = PCA()
pca.fit(X2)

[7]: PCA ⓘ ?
    ▸ Parameters
    ▸ Fitted attributes

    ▸ 4 features 📄

[8]: #Eigenvalores
from numpy import linalg as LA
print("Eigenvalores:")
print(LA.eigvals(A))

Eigenvalores:
[2.91849782 0.91403047 0.14675688 0.02071484]
```

Como siguiente paso calculamos el porcentaje de la varianza explicada por cada componente principal, y sumamos los dos primeros para poder conocer qué grado de información original se conserva al reducir a solo 2 dimensiones.

```
[18]: # Porcentaje de varianza explicada por cada componente
print("Porcentaje de varianza explicada por componente")
print(pca.explained_variance_ratio_)

# Sumamos los dos primeros (PC1 + PC2)
varianza_2pc = pca.explained_variance_ratio_[0] + pca.explained_variance_ratio_[1]
print(f"\nVarianza explicada por PC1 + PC2: {varianza_2pc*100:.2f}%")

Porcentaje de varianza explicada por componente
[0.72962445 0.22850762 0.03668922 0.00517871]


Varianza explicada por PC1 + PC2: 95.81%
```

Los dos primeros componentes principales (PC1 y PC2) explican en conjunto el 95.81% de la varianza total de los datos. Esto significa que, aunque la base original tiene 4 variables numéricas casi toda la información relevante se puede representar en un plano de solo 2 dimensiones esto sin perder casi nada de información.

Paso 3: Mapa de observaciones y mapa de factores

Construimos los gráficos con los dos primeros componentes principales. El mapa de observaciones nos ubica cada flor en el plano PC1-PC2, se coloreo por especies (Setosa, Versicolor, Virginica) esto para poder facilitar los grupos. El mapa de factores muestra la

contribución de cada variable original a los dos primeros componentes principales de PC1 y PC2.



Comparación de los mapas:

En el mapa de factores podemos observar que petal.length y petal.width están muy cerca entre sí y están alineadas principalmente con el eje PC1, esto indica que ambas variables están correlacionadas y son las que contribuyen al primer componente. Sepal.length también contribuye a PC1, aunque con menor medida. En cambio, sepal.width se separa de las demás variables y esta contribuye sobre todo a PC2, esto indica que está poco

correlacionada con el tamaño del pétalo. En el mapa de observaciones podemos distinguir dos grupos que están separados a lo largo del eje de PC1, el grupo a la izquierda (son los valores negativos de PC1) y otro grupo que es más disperso a la derecha (valores positivos), esta separación tiene una coincidencia con la dirección de petal.length y petal.width en el mapa de factores, esto sugiere que el eje PC1 está determinado principalmente por el tamaño del pétalo.

Conclusión:

Al comparar ambos mapas podemos observar que la separación de las observaciones en el eje de PC1 corresponde principalmente a las variables petal.length y petal.width, ya que son las que tienen mayor peso sobre ese componente en el mapa de factores. Esto nos sugiere que las flores que se agrupan del lado izquierdo del mapa de observaciones comparten valores bajos en su tamaño de pétalo, mientras que la del lado derecho tiene valores altos en esas mismas variables. Sepa.width contribuye muy poco a la separación en PC1 y se relaciona con PC2 dentro de cada grupo.